SISTEMI MULTI-AGENTE PER L'ANALISI DOCUMENTALE VOCALE

Capitolo 1: Architettura di Sistema e Obiettivi

L'assistente documentale Hermes Voice è progettato per operare in ambienti ad alta affidabilità su sistemi Windows 11. Il principio cardine del sistema è la separazione netta tra la lettura deterministica del documento e le capacità di interrogazione analitica. Nessun modello linguistico è autorizzato a parafrasare o riscrivere il testo originale durante la sessione di ascolto.

La configurazione hardware di riferimento prevede un processore Intel Core Ultra 7 con 16 gigabyte di memoria RAM e grafica integrata. In questa prima iterazione, la sintesi vocale è affidata a Pocket TTS sviluppato da Kyutai Labs, con la voce Giovanni configurata sia per il modello standard italiano che per la variante avanzata a ventiquattro livelli.

Capitolo 2: Prestazioni della Sintesi Vocale e Routing LLM

I benchmark eseguiti localmente hanno dimostrato che il modello italiano distillato di Pocket TTS raggiunge una velocità di generazione pari a 2.6 volte il tempo reale su CPU, con un tempo medio per passo di generazione di 27 millisecondi. Al contrario, il modello non distillato a 24 livelli opera a 0.54 volte il tempo reale, richiedendo 138 millisecondi per passo.

Per quanto concerne l'interrogazione del contenuto, il router dei modelli indirizza le richieste in via predefinita a un'istanza locale di Ollama equipaggiata con il modello gemma4 da 12B. Questa scelta garantisce la totale riservatezza dei dati aziendali ed esclude l'invio non autorizzato di informazioni riservate verso server esterni o provider remoti.

Capitolo 3: La Triade di Agenti e Criteri di Accettazione

La gestione dell'interazione è articolata in tre ruoli complementari: il Bibliotecario, l'Analista e il Verificatore. Il Bibliotecario indicizza i paragrafi ed estrae i frammenti pertinenti con i relativi numeri di pagina. L'Analista formula le risposte formulando citazioni esplicite. Infine, il Verificatore controlla la fedeltà delle risposte rispetto al testo sorgente ed elimina ogni possibile allucinazione.

Il criterio di successo vincolante prevede che l'utente possa avviare la riproduzione, interromperla a proprio piacimento, formulare una domanda ottenendo riscontri verificabili con numero di pagina esatto, e riprendere la lettura dal punto preciso in cui era stata sospesa.